

TỔNG QUAN VỀ BIG DATA

Lê Anh Quân



MỤC LỤC

I. Tổng quan về Big Data

1. Big Data là gì?
2. Các lớp trong Big Data và chức năng của chúng

II. Các loại dữ liệu

1. Structured Data
2. Semi-structured Data
3. Unstructured Data


III. Các loại cơ sở dữ liệu lớn

1. Data Warehouse
2. Data Lake
3. Data Lakehouse

IV. Hortonwork Data Platform (HDP)


BIG DATA LÀ GÌ?

Big Data (Dữ liệu lớn) là thuật ngữ chỉ các tập dữ liệu có khối lượng lớn khổng lồ, tốc độ tạo ra cực nhanh và cực kỳ phức tạp. Chúng vượt quá khả năng thu thập, lưu trữ và phân tích của các công cụ phần mềm truyền thống. Dữ liệu này đến từ mạng xã hội, thiết bị thông minh (IoT), hay các giao dịch trực tuyến.



DATA SOURCE


Data Source (lớp nguồn dữ liệu) trong Big Data là nơi khởi nguồn của khối lượng thông tin khổng lồ đa dạng. Chúng được phân loại thành 4 nguồn chính: dữ liệu mạng xã hội, dữ liệu giao dịch kinh doanh, dữ liệu thiết bị (IoT) và dữ liệu khoa học. Các nguồn này tạo ra thông tin liên tục và đòi hỏi công nghệ lưu trữ, xử lý chuyên biệt.

Typical Data Source	Internal Data Source	Semi/Unstructured Data Source
 Market Research & Competitive Information	 Viewership	 Clickstream
 Audience Demographics	 Advertisements	 Social Media
	 Merchandise	 Content
	 Sales & Finance	


DATA INGESTION

Data Ingestion là quá trình thu thập và di chuyển khối lượng lớn dữ liệu từ nhiều nguồn khác nhau (IoT, mạng xã hội, ERP) vào hệ thống lưu trữ trung tâm (Data Lake, Data Warehouse). Đây là bước khởi đầu thiết yếu trong kiến trúc Big Data, đảm bảo dữ liệu sẵn sàng để phân tích và xử lý. Quá trình này chủ yếu được thực hiện thông qua ba phương pháp chính:

- Batch Ingestion (Thu thập theo lô)
- Real-Time/Streaming Ingestion (Thời gian thực)
- Micro-Batching



DATA STORAGE



Data Storage trong Big Data là việc sử dụng hệ thống tệp phân tán và các kiến trúc lưu trữ đám mây để lưu giữ khối lượng dữ liệu khổng lồ (Volume) với tốc độ cao (Velocity) và đa dạng định lượng (Variety), vượt quá khả năng xử lý của cơ sở dữ liệu truyền thống. Các kiến trúc lưu trữ phổ biến bao gồm:

- Data Lake
- Data Warehouse
- Data Lakehouse

DATA PROCESSING

Các kỹ thuật tiền xử lý dữ liệu phổ biến



Xử lý giá trị thiếu



Loại bỏ dữ liệu nhiễu



Loại bỏ dữ liệu trùng lặp



Biến đổi và chuẩn hóa dữ liệu



Giảm chiều dữ liệu



Mã hóa dữ liệu danh mục



Rời rạc hóa dữ liệu



Xử lý dữ liệu mất cân bằng

DATA ANALYTICS

Analytics/Query trong Big Data là quá trình thu thập, xử lý và diễn giải các tập dữ liệu khổng lồ nhằm khám phá các xu hướng ẩn, mô hình và thông tin giá trị. Nó giúp doanh nghiệp tối ưu hóa hoạt động, dự đoán thị trường và đưa ra các quyết định chính xác. Các loại hình phân tích chính bao gồm:

- Phân tích mô tả (Descriptive)
- Phân tích chẩn đoán (Diagnostic)
- Phân tích dự đoán (Predictive)
- Phân tích đề xuất (Prescriptive)



DATA VISUALIZATION

Data Visualization trong Big Data là quá trình chuyển đổi các tập dữ liệu khổng lồ (Volume) và đa dạng (Variety) thành các dạng trực quan như biểu đồ, bản đồ hoặc dashboard. Đây là bước then chốt giúp doanh nghiệp hiểu được dữ liệu, phát hiện các xu hướng ẩn giấu và đưa ra quyết định nhanh chóng.



STRUCTURED DATA

Structured Data (Dữ liệu có cấu trúc) là loại dữ liệu được tổ chức theo các mô hình hoặc khuôn mẫu định sẵn, thường được lưu trữ dưới dạng bảng gồm các hàng và cột. Nó tuân thủ các lược đồ (schema) rõ ràng, giúp cả con người và máy tính dễ dàng truy xuất, tìm kiếm và phân tích.

Core Characteristics of Structured Data



SEMI-STRUCTURED DATA


Semi-structured Data



Semi-structured Data (Dữ liệu bán cấu trúc) là dạng dữ liệu có tổ chức nhưng không tuân theo một khuôn mẫu bảng cứng nhắc như RDBMS. Thay vì dùng hàng và cột, dữ liệu này thường được lưu trữ dưới dạng các tệp văn bản như JSON, XML hoặc YAML.


UNSTRUCTURED DATA

Unstructured Data (dữ liệu phi cấu trúc) là thông tin không tuân theo mô hình, định dạng hoặc lược đồ dữ liệu được xác định trước. Loại dữ liệu này không thể lưu trữ trong các cơ sở dữ liệu dạng bảng truyền thống mà thường tồn tại dưới dạng các tệp văn bản, hình ảnh, âm thanh hoặc video.




DATA WAREHOUSE

Data Warehouse (DWH) là hệ thống lưu trữ tập trung dữ liệu lịch sử và hiện tại từ nhiều nguồn khác nhau. Mục đích chính của DWH là phục vụ phân tích, lập báo cáo và hỗ trợ ra quyết định kinh doanh, thay vì chỉ xử lý các giao dịch hàng ngày.




DATA LAKE

Data Lake (hồ dữ liệu) là một kho lưu trữ tập trung cho phép lưu trữ khối lượng lớn dữ liệu ở dạng nguyên bản (raw data). Nó chứa mọi loại dữ liệu (có cấu trúc, bán cấu trúc và phi cấu trúc) mà không cần phải phân loại, làm sạch hay xử lý trước khi lưu.



DATA LAKEHOUSE

Data Lakehouse là một kiến trúc quản lý dữ liệu hiện đại kết hợp ưu điểm của Data Lake (lưu trữ linh hoạt, chi phí rẻ) và Data Warehouse (quản lý cấu trúc tốt, hiệu suất cao). Nó cho phép doanh nghiệp lưu trữ mọi loại dữ liệu và trực tiếp thực hiện phân tích hay học máy (Machine Learning) trên cùng một hệ thống.



HORTONWORK DATA PLATFORM

Hortonwork Data Platform (HDP) là một nền tảng dữ liệu lớn (Big Data) mã nguồn mở, được xây dựng dựa trên Apache Hadoop. Nền tảng này cung cấp cho doanh nghiệp bộ công cụ toàn diện để lưu trữ, quản lý, xử lý và phân tích khối lượng dữ liệu khổng lồ từ nhiều nguồn khác nhau.

Hortonwork Data Platform phù hợp nhất cho các bài toán xử lý dữ liệu lớn ở quy mô từ vài Terabyte đến hàng Petabyte, nơi các cơ sở dữ liệu truyền thống không thể đáp ứng được. Các bài toán tiêu biểu bao gồm:

- Xây dựng Hồ dữ liệu doanh nghiệp (Enterprise Data Lake)
- Phân tích dữ liệu và Báo cáo nâng cao (Advanced Analytics)
- Xử lý dữ liệu thời gian thực (Real-time Streaming & IoT)
- Học máy và Trí tuệ nhân tạo (Machine Learning & AI)

